第2回：ヒトはどのように声を出し、聴くのか

音声処理と認識

担当：小野原彩香
形式：オンライン同期（Zoom）

📌 Zoom録画を後日公開します。課題はメール/Google Driveでも提出可。

今日のアジェンダ

1. 前回の振り返りクイズ（Zoomチャット）
2. 発話器官のしくみ
3. 調音音声学の基礎
4. 音声の音響的特性（ソース-フィルタモデル・フォルマント）
5. 聴覚系のしくみ
6. 人間の音声知覚の特性
7. 人間と機械の比較
8. グループディスカッション
9. まとめ・小課題

事前学習の確認クイズ

Q1：「マクガーク効果」とはどのような現象か？（Zoomチャットに書き込む）

A) 騒音の中でも特定の人の声を聞き分けられる現象
B) 映像の口の動きが聴こえる音の知覚に影響を与える現象
C) 自分の録音した声が普段の声と違って聞こえる現象
D) 外耳道の形が音の方向知覚に影響を与える現象

Q2：自分の録音した声を聴いて、どう感じましたか？（自由記述）

発話は複数の器官の協調動作

> 頭部・胸部の断面図（矢状断面）：肺 → 気管 → 喉頭（声帯）→ 咽頭 → 口腔 → 鼻腔

器官	発話における役割
肺	呼気（吐く息）の動力源。声の大きさのエネルギーを供給
声帯	気流を周期的に遮断し、音源となる振動を作る
声道	喉から口・鼻までの空間。形状変化でフォルマントを制御
舌	口腔内形状を最も細かく制御する器官
唇	開閉・突き出しで音色を変える
鼻腔	軟口蓋が下がると鼻音（m・n・ng）が生まれる

声のしくみ：ソース-フィルタモデル

> **ソース（声帯）→ フィルタ（声道）→ 出力（口から出る声）**

ソース（音源）

- 声帯振動による基本周波数 F_0 と豊富な倍音を含む信号
- F_0 が高い＝高い声（女性：200〜300 Hz、男性：100〜150 Hz）
- 無声音では声帯は振動せず、乱流（摩擦音）がソースになる

フィルタ（声道）

- 声道の形（長さ・くびれの位置）が共鳴周波数＝**フォルマント**を決める
- 舌・唇・軟口蓋を動かすことで異なる母音・子音が生まれる

有声音と無声音

有声音（Voiced）：声帯が振動している状態

- 日本語：母音すべて（ア・イ・ウ・エ・オ）、濁音（ガ・ザ・ダ・バ行）、鼻音
- 英語：/b/, /d/, /g/, /v/, /z/

無声音（Voiceless）：声帯が振動しない状態

- 日本語：カ・サ・タ・ハ・パ行の清音
- 英語：/p/, /t/, /k/, /f/, /s/

> **体験実験（全員で）**：喉に手を当てて「ア」→「ス」と発音してみよう。「ア」は振動が感じられ、「ス」は感じられない。

子音の分類：調音様式と調音部位

調音様式（どのように音を作るか）

調音様式	説明	日本語の例
閉鎖音（破裂音）	気道を完全閉鎖→一気に開放	カ・タ・パ行
摩擦音	気道を狭めて乱流を作る	サ行・ハ行
鼻音	鼻に気流を通す	マ行・ナ行
弾き音	舌先が歯茎に瞬間的に触れる	ラ行
接近音（半母音）	母音に近い形で調音	ヤ行・ワ行

調音部位（どこで音を作るか）

- 両唇音：/p/ /b/ /m/ ／ 歯茎音：/t/ /d/ /n/ /s/ /z/ ／ 軟口蓋音：/k/ /g/

母音はフォルマントで区別される

母音四角形：横軸＝舌の前後（左＝前舌）、縦軸＝舌の高さ（上＝高）
イ（左上）・エ（左中）・ア（下中央）・オ（右中）・ウ（右上）

- **F1（第1フォルマント）**：舌の高さと**逆相関**（舌が低い「ア」→ F1 高い）
- **F2（第2フォルマント）**：舌の前後と**相関**（前舌「イ」→ F2 高い）

日本語5母音の典型的フォルマント値（成人女性）

母音	F1 (Hz)	F2 (Hz)
ア /a/	900	1500
イ /i/	320	2700
ウ /u/	390	1300
エ /e/	600	2200
オ /o/	550	1000

耳はどのように音を処理するか

耳の断面図（横断面）：外耳 → 鼓膜 → 中耳（耳小骨3個）→ 内耳（蝸牛）→ 聴神経 → 脳

区域	主な器官	役割
外耳	耳介・外耳道	音波を集め鼓膜に伝える。耳介の形が方向知覚を助ける
中耳	鼓膜・耳小骨（3個）	空気振動を機械振動に変換・増幅（約30倍に増幅）
内耳	蝸牛・前庭	機械振動を電気信号に変換（周波数分析も行う）

蝸牛：カタツムリ型の周波数分析器

蝸牛を展開した図：左端（基底部）= 高周波数（8000〜20000 Hz）に反応、右端（頂点部）= 低周波数（20〜1000 Hz）に反応

蝸牛の重要な特性

1. **周波数の場所的対応（Tonotopy）**：高周波数は入口側、低周波数は奥側で反応
2. **機械→電気変換**：基底膜の振動により有毛細胞が電気信号を生成
3. **非線形な感度**：小さい音も大きい音も動的に処理（メル尺度の基礎）

コンピュータとの類比：蝸牛の「場所による周波数分析」は、コンピュータの「フーリエ変換」に対応する（第4回で詳しく扱う）

音声は「目」でも聴く ― マクガーク効果

1976年、McGurk & MacDonald が報告した現象

実験の手順

- 口が「ガ（ga）」と動く映像に「バ（ba）」の音声を重ねて提示
- 多くの聴取者には「ダ（da）」または「ガ」と知覚される
- 目をつむって音だけ聴くと「バ」と聞こえる

この現象が示すこと

- 音声知覚は「聴覚だけの処理」ではなく、視覚との統合処理
- 脳は「もっともらしい音声」を能動的に構築している
- 機械の音声認識は通常この視覚-聴覚統合を行わない（マルチモーダルASRが応用）

騒音の中で声を選別する — カクテルパーティ効果

大勢が話す環境でも特定の人の声だけに注意を向けて聞き取れる現象

Cherry（1953）の研究：左耳・右耳に異なるメッセージを提示する両耳分離聴実験

比較軸	人間	機械
注意の選択性	声の方向・音色・話者への注意で選別	単純な方向マイクでは限界がある
事前知識の活用	話者の声質・話題の文脈で補完	文脈情報の活用は研究段階
適応的ノイズ除去	脳が自動的に背景音を抑制	ビームフォーミング等の信号処理が必要

技術的対応：ビームフォーミング・Wienerフィルタ・深層学習による話者分離

音声知覚の「不思議」な現象たち

カテゴリカル知覚（Categorical Perception）

- /b/ から /p/ への連続的な変化も、人間は「境界」で急に切り替わって知覚する
- 中間的な音があっても「どちらかに聞こえる」

音素修復効果（Phoneme Restoration）

- 「THE STATE GOV_RNORS」（_はノイズ）の欠落部分を脳が「E」として補完
- 脳は欠落した情報を文脈から補完している

プライミング効果

- 直前に聴いた言葉が次の言葉の知覚を速める・遅らせる
- 「知覚は文脈の中で起きる」

人間の聴覚 vs. 機械の音声認識

比較軸	人間	機械（現代のASR）
周波数分析	蝸牛（場所コード）・リアルタイム	FFT/メルフィルタバンク
ノイズ耐性	高い（カクテルパーティ効果等）	低〜中（静かな環境では人間並み）
方言・アクセント	適応力が高い	学習データに依存
少量データからの学習	数例で可能（Few-shot）	大量データが必要（例外あり）
多感覚統合	視覚・文脈を自動的に使う	専用のマルチモーダル設計が必要
感情・意図の理解	高い（非言語情報も含む）	研究段階

> 人間の聴覚は注意・記憶・文脈・視覚が統合された多次元システムである

グループディスカッション（20分）

実施方法

- Zoom参加者はグループ（3〜4人）に分かれて議論する
- 20分後に各グループが2〜3分で発表する
- 発言が苦手な場合はテキストチャットでの参加でも構わない
- Zoomに参加できない場合は、テーマを選んでメールで意見を送ってもよい

> 発表は「正解を言う」ことが目的ではありません。議論のプロセスと考え方を共有してください。

テーマ割り当て（以下のスライドを参照）

ディスカッション：テーマA

「機械に人間のカクテルパーティ効果を実現させるには？」

- マイクのハードウェア面（マイクアレイ等）で何ができるか？
- 信号処理・機械学習でどんなことができるか？
- 「特定の声を選ぶ」には、事前にどんな情報が必要か？
- 実際の製品（スマートスピーカー・補聴器）はどう対処しているか？

発表でまとめること：考えたアプローチを2〜3つ挙げ、各アプローチの難しい点も述べる

ディスカッション：テーマB

「音声認識のバイアスとはどういう問題か？どう対処すべきか？」

- 学習データの偏りとは何か？（誰がデータを提供したか）
- 声の物理的特性（声の高さ・フォルマント分布）の多様性はどう扱われているか？
- バイアスのある音声認識が社会で使われるとどんな問題が起きうるか？

発表でまとめること：バイアスが生じるメカニズム＋役割別（開発者・利用者・政策）の対策

ディスカッション：テーマC

「マクガーク効果から見えること ― 音声とは何か？」

- なぜ人間の脳は映像と音声を統合して知覚するのか？（進化的・機能的な理由）
- Zoomやオンライン会議でマスクをしているとき、コミュニケーションはどう変わるか？
- 機械がマクガーク効果を「再現」するとしたら、どのような技術が必要か？

発表でまとめること：「音声を理解する」ことの人間と機械の本質的な違いを1〜2文でまとめ、グループで最も面白いと思ったアイデアを共有する

やってみよう！音声知覚の体験実験

演習1：有声音・無声音の識別（5分）

- 教員がマイクで音を5つ出す → Zoomチャットで「有声音」か「無声音」かを書き込む
- 出題例：「ザ」（有声）・「サ」（無声）・「ムー」（有声）・「フ」（無声）・「ン」（有声）

演習2：フォルマントの体感実験（5分）

- 「アー」と発音しながら口の形を「イ」に近づけていく
- 音の変化をZoomチャットに書き込む
- 「アからイに変わると鋭い感じがする」→ F2 が上がっていることの体験

演習3：マクガーク効果の動画鑑賞（5分）

- YouTube動画をスクリーン共有 → チャットで「何と聞こえましたか？」を書き込む

次回（第3回）の予告

形式：動画回（非同期・自分のペースで視聴）
テーマ：音をコンピュータで扱うための数値化
内容：サンプリング・量子化・ナイキスト定理・WAVファイル・Pythonで音声を読む

事前学習（任意推奨）

1. 手元の音楽ファイルのプロパティを確認し「サンプリングレート」「ビット深度」を探す
   （Windows：ファイル右クリック→プロパティ→詳細）
2. 「なぜCDは44.1kHzなのか」を検索してみる

第2回のまとめ

1. ヒトの発話は「肺（呼気）→ 声帯（振動）→ 声道・口・鼻（フィルタ）」というソース-フィルタ構造で説明できる
2. 子音は調音部位と調音様式で分類され、フォルマント（F1・F2）が母音を区別する主要な手がかりになる
3. 耳の蝸牛は周波数ごとに異なる場所で反応する周波数アナライザである
4. 人間の音声知覚はマクガーク効果・カクテルパーティ効果に見られるように、多感覚統合・注意・文脈を使った能動的な処理である
5. 機械の音声認識は人間の聴覚の一側面を数学的に再現したもの

小課題：翌週末23:59 までに Google Drive または メールで提出（400〜600字程度）