第5回：音響特徴量（MFCC）の原理とPython実装

音声処理と認識

担当：小野原彩香｜北星学園大学｜3年後期

📌 この回は動画回です。Google Formsでテストを受けてください。

本回の到達目標

1. メル尺度が人間の聴覚特性を反映する理由を説明できる
2. MFCCの計算ステップを順に説明できる
3. Pythonで MFCC を計算・可視化できる
4. デルタ特徴量の意味を説明できる

人間の耳の非線形性

人間は **すべての周波数を等しく聴いていない**

物理的差	知覚される差
100Hz → 200Hz（差 100Hz）	とても大きな差
5000Hz → 5100Hz（差 100Hz）	ほとんど感じない

低音域：小さな差を敏感に感じる
高音域：大きな差でも鈍感

> **直感**：ピアノで1オクターブ上がると周波数は2倍。どの1オクターブも同じ音程差に聞こえる = **対数的な知覚**

メル尺度の定義

$$m = 2595 \log_{10}\left(1 + \frac{f}{700}\right)$$

逆変換（メル → Hz）：

$$f = 700\left(10^{m/2595} - 1\right)$$

周波数 (Hz)	メル (Mel)
0	0
700	≈ 1000（中間点）
7000	≈ 2590

700 Hz 以下：ほぼ線形、700 Hz 以上：対数的に圧縮

メルフィルタバンク

メル尺度で **等間隔に並んだ三角形フィルタ群** でスペクトルをまとめる

```
FFTスペクトル（例：1025ビン）
    ↓
三角フィルタをかける（例：40個）
    ↓
各フィルタ内のエネルギーを合計
    ↓
40次元のメルエネルギーベクトル
```

k番目のフィルタ出力：

$$S[k] = \sum_n X[n] \cdot H_k[n]$$

- 低周波：フィルタが**狭い**（細かく分析）
- 高周波：フィルタが**広い**（まとめて分析）

ログメルスペクトログラム

なぜ対数を取るか

1. 人間の聴覚はエネルギーに対して対数的（ウェーバー-フェヒナーの法則）
2. 静かな音と大きな音のダイナミックレンジが非常に広い
3. 機械学習モデルが扱いやすい数値範囲になる

$$\mathrm{LogMel}[k] = \log(S[k] + \epsilon)$$

- $S[k]$：k番目のメルフィルタバンクの出力
- ϵ：ゼロ除算防止の微小値（例：10^{-9}）

> 現代の深層学習モデル（Whisper、wav2vec）はこのログメルスペクトログラムを直接入力として使うことが多い

DCT（離散コサイン変換）の役割

$$C[n] = \sum_{k=0}^{K-1} \log S[k] \cdot \cos\left(\frac{\pi n (k + 0.5)}{K}\right)$$

DCTをかける3つの目的

1. **圧縮**：40〜128次元 → 13〜40次元に削減
2. **非相関化**：隣接フィルタの相関を除去し、独立した成分に分離
3. **エネルギー分離**：C[0]は全体エネルギー、高次は細かいスペクトル形状

DCT係数次数	表すもの
C[1]〜C[4]	大まかなスペクトル形状（フォルマント）
C[5]〜C[12]	細かいスペクトル形状
C[13]以上	ノイズ的、音声認識にはほぼ不要

MFCCの計算ステップ全体

入力：音声波形 $x[n]$

↓

① プリエンファシス　$x'[n] = x[n] - \alpha \cdot x[n-1]$　($\alpha \approx 0.97$)

↓

② フレーム分割 + 窓掛け（ハニング窓）25ms、10msシフト

↓

③ FFT → パワースペクトル　$|X[k]|^2$

↓

④ メルフィルタバンク　$S[m] = \Sigma\ H_m[k] \cdot |X[k]|^2$

↓

⑤ 対数　$\log S[m]$

↓

⑥ DCT　$C[n] = \Sigma\ \log S[m] \cdot \cos(\pi \cdot n \cdot (m+0.5)/M)$

↓

出力：MFCC（例：13次元ベクトル）× フレーム数

Python実装：librosaでMFCC計算

```
import librosa
import librosa.display
import numpy as np
import matplotlib.pyplot as plt

# 音声読み込み
y, sr = librosa.load(librosa.example('trumpet'), sr=22050)

# MFCC を計算（13次元）
mfcc = librosa.feature.mfcc(y=y, sr=sr,
                            n_mfcc=13,
                            n_fft=2048,
                            hop_length=512,
                            n_mels=40)

print(f"MFCCの形状: {mfcc.shape}")
# → （13, フレーム数）
```

デルタ（Δ）特徴量

MFCCだけでは「ある瞬間のスペクトル形状」しかわからない

→ 時間的な変化を特徴量に加える

$$\Delta C_t[n] = \frac{\sum_{k=1}^{K} k \left(C_{t+k}[n] - C_{t-k}[n] \right)}{2 \sum_{k=1}^{K} k^2}$$

（通常 $K = 2$、前後2フレームを使用）

構成	次元数	用途
MFCC	13	最小構成
MFCC + Δ	26	標準的
MFCC + Δ + ΔΔ	39	音声認識の定番

```
mfcc_d  = librosa.feature.delta(mfcc, width=5)         # 1次差分
mfcc_dd = librosa.feature.delta(mfcc, width=5, order=2) # 2次差分
mfcc_39 = np.concatenate([mfcc, mfcc_d, mfcc_dd], axis=0)
```

MFCCの実用的な設定

n_mfcc	n_mels	用途
13	26〜40	従来の音声認識（GMM-HMM）
20	40	深層学習の中間的な選択
40	80〜128	深層学習（高精度モデル）
80	128	Whisper、wav2vec等の最新モデル

パラメータ	典型値	意味
`sr`	16000, 22050	サンプリングレート（Hz）
`n_fft`	512〜2048	FFT長（≒フレーム長）
`hop_length`	256, 512	フレームシフト幅
`fmin` / `fmax`	0〜sr/2	分析周波数範囲

Google Forms テスト（全5問）

締め切り：翌週末 23:59

問1：メル尺度について正しい説明はどれか
A. 全帯域を線形スケールで表したもの
B. 高音域を拡張したもの
C. 低音域を細かく、高音域を粗く扱うもの ✓
D. 基本周波数F0を検出するための尺度

問2：MFCCの正しい計算順序はどれか
A. FFT → メルフィルタ → 対数 → DCT ✓
B. DCT → FFT → メルフィルタ → 対数
C. メルフィルタ → FFT → 対数 → DCT
D. FFT → 対数 → メルフィルタ → DCT

まとめ

概念	ポイント
メル尺度	人間の聴覚特性（低音を細かく、高音を粗く）を数値化
メルフィルタバンク	三角形フィルタをメル尺度で等間隔に配置
ログメルスペクトログラム	メルエネルギーの対数。深層学習で多用
DCT	相関除去＋次元圧縮。MFCCの最終ステップ
MFCC	音声認識の定番特徴量。13〜40次元
Δ・ΔΔ特徴量	時間変化を特徴量に加える。39次元が定番

次回（第6回・オンライン同期）：ピッチ・エネルギー・ゼロ交差などの前処理手法と音声活動検出（VAD）

Google Forms テスト

第5回の理解度テストを受けてください

- 全5問・各1点
- 締め切り：**翌週末 23:59**
- Google Formsのリンクはメールまたは授業ページで確認してください

お疲れさまでした！