第6回：ピッチ・エネルギー・ゼロ交差などの前処理

音声処理と認識

担当：小野原彩香｜北星学園大学｜3年後期

📌 Zoom録画を後日公開します。課題はメール/Google Driveでも提出可。

本日の到達目標

1. ZCR・RMS・ピッチ（F0）の定義と計算方法を説明できる
2. これらの特徴量で有声音・無声音・無音を判定できる
3. Pythonで4特徴量（波形・ZCR・RMS・F0）を同時可視化できる
4. 音声活動検出（VAD）の基本的な仕組みを説明できる

フレーム分割と窓掛けの復習

音声処理はすべて**短い区間（フレーム）ごとに処理**するところから始まる

```
音声波形全体（例：3秒、66150サンプル @22050Hz）
  ↓ フレーム分割
フレーム1: サンプル    0〜 1023
フレーム2: サンプル  512〜 1535  ← 50%オーバーラップ
フレーム3: サンプル 1024〜 2047 ...
  ↓ 窓掛け（ハニング窓）
  ↓ 特徴量抽出（ZCR・RMS・F0・MFCC など）
```

パラメータ	典型的な値	備考
フレーム長	25ms（≈ 512〜2048サンプル）	1フレームの長さ
ホップサイズ	10〜12.5ms（フレーム長の50%）	フレームをずらす幅
窓関数	ハニング窓	スペクトル漏れを防ぐ

ゼロ交差率（ZCR）の定義

ゼロ交差：波形が正から負（または負から正）に**ゼロをまたいで変化する瞬間**

$$\mathrm{ZCR}[m] = \frac{1}{2N} \sum_{n=1}^{N} \left| \mathrm{sgn}(x_m[n]) - \mathrm{sgn}(x_m[n-1]) \right|$$

- N：フレーム内のサンプル数
- $\mathrm{sgn}(\cdot)$：符号関数（正なら+1、負なら−1）

ZCRの値	音の種類
高い（> 0.3）	無声音（さ・し行）や環境ノイズ → 高周波成分が多い
低い（< 0.1）	有声音（母音・鼻音） → 低周波成分が主体

```
zcr = librosa.feature.zero_crossing_rate(y,
                frame_length=2048, hop_length=512)[0]
```

エネルギー（RMS）の定義

RMS（Root Mean Square：二乗平均平方根）

$$\mathrm{RMS}[m] = \sqrt{\frac{1}{N}\sum_{n=0}^{N-1} x_m[n]^2}$$

> 単純平均は音声の正負が打ち消し合うのでゼロに近くなる。二乗することで符号を消してエネルギーを正しく測る。

dB（デシベル）表現

$$\mathrm{RMS}_{dB}[m] = 20\log_{10}(\mathrm{RMS}[m] + \epsilon)$$

```
rms    = librosa.feature.rms(y=y,
                frame_length=2048, hop_length=512)[0]
rms_db = librosa.amplitude_to_db(rms, ref=np.max)
```

無音：RMS が低い（例：-50 dB 以下）→ VADの閾値として使用

ZCR + RMS による有声・無声・無音判定

音の種類	RMS	ZCR	説明
無音	低	どちらでも	エネルギーなし
有声音	高	低	声帯振動 → 低周波主体
無声音	中〜高	高	摩擦音 → 高周波主体

```
def rule_based_vad(zcr, rms_db,
                   zcr_threshold=0.1, rms_threshold=-30):
    labels = []
    for z, r in zip(zcr, rms_db):
        if r < rms_threshold:
            labels.append('silence')
        elif z < zcr_threshold:
            labels.append('voiced')
        else:
            labels.append('unvoiced')
    return labels
```

ピッチ（基本周波数 F0）の概念

$$F_0 = \frac{1}{T_0}$$

- T_0：1回の声帯振動にかかる時間（基本周期）
- F_0 大 → 高い声、F_0 小 → 低い声

グループ	F0の典型的な範囲
成人男性	85〜180 Hz
成人女性	165〜300 Hz
子ども	250〜450 Hz

F0 vs フォルマント

	F0（ピッチ）	フォルマント（F1, F2, ...）
物理的実体	声帯の振動周波数	声道の共鳴周波数
変化の要因	声帯の張り・イントネーション	口・舌・唇の形
音声認識での役割	韻律解析	音素識別（母音の区別）

YINアルゴリズムによるピッチ推定

自己相関関数（ACF） で信号の周期性を検出するのが基本アイデア

$$R_x[\tau] = \sum_{n=0}^{N-1} x[n] \cdot x[n+\tau]$$

YIN（de Cheveigné & Kawahara 2002） は差分関数を使った高精度版

$$d[\tau] = \sum_{n} \left(x[n] - x[n+\tau] \right)^2$$

1. 差分関数 $d[\tau]$ を計算
2. 累積平均正規化（CMND）でノイズに対してロバスト化
3. 閾値以下の極小値を探索 → 基本周期 T_0
4. 放物線補間で精度向上

```
f0 = librosa.yin(y, fmin=50, fmax=500,
                 sr=sr, hop_length=512)
f0_voiced = np.where(f0 >= 500, np.nan, f0)
```

Python実習：4特徴量の複合可視化

```
import librosa, librosa.display
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.gridspec as gridspec

y, sr = librosa.load(librosa.example('trumpet'), sr=22050)
hop_length, frame_length = 512, 2048

zcr    = librosa.feature.zero_crossing_rate(
             y, frame_length=frame_length, hop_length=hop_length)[0]
rms    = librosa.feature.rms(
             y=y, frame_length=frame_length, hop_length=hop_length)[0]
rms_db = librosa.amplitude_to_db(rms, ref=np.max)
f0     = librosa.yin(y, fmin=50, fmax=500,
                     sr=sr, hop_length=hop_length)
f0_voiced = np.where((f0 >= 500) | (f0 <= 50), np.nan, f0)

times = librosa.frames_to_time(
    np.arange(len(zcr)), sr=sr, hop_length=hop_length)
```

音声活動検出（VAD）の基礎

VAD（Voice Activity Detection）：音声区間と非音声区間を自動識別する技術

```
入力音声ストリーム
  ↓ VAD
  ├─ 音声区間 → 音声認識エンジンへ送る
  └─ 非音声区間 → スキップ
```

アプローチ	特徴	代表例
ルールベース	ZCR + RMS の閾値処理	本日実装したもの
統計的	GMM + HMM	WebRTC VAD
深層学習	LSTM, Transformer	Silero VAD, pyannote

VADが重要な理由

- 計算コスト削減：無音区間を処理しない
- 精度向上：無音区間のノイズが認識結果を汚染しない
- プライバシー保護：会話していないときのデータを収集しない

演習：特徴量パターンから音声を推測

以下の3つのパターンを見て、どんな音声か推測しよう

ケース	ZCR	RMS	F0
A	低（0.05〜0.08）、時々0.3超	高低が規則的に交互	130〜180Hz で安定
B	常に高い（0.2〜0.35）	非常に低い（-50dB以下）	ほとんど未検出
C	低い区間と高い区間が混在	高い値が持続（-10〜-15dB）	200〜280Hz と NaN が交互

チャット or Google Drive で回答を提出してください

まとめ

特徴量	計算式	高い値	低い値
ZCR	符号変化の回数	無声音・高周波ノイズ	有声音・低周波
RMS	二乗平均平方根	大きな音	静かな音・無音
F0	YINアルゴリズム	高い声	低い声

librosaで使ったキーな関数

```
librosa.feature.zero_crossing_rate()  # ZCR
librosa.feature.rms()                 # RMS
librosa.yin()                         # F0（YINアルゴリズム）
librosa.amplitude_to_db()            # dBスケール変換
```

次回（第7回・動画回）：HMM（隠れマルコフモデル）とGMMの基礎。確率的モデルで音声の時間変化を表現します。

予習：「状態」「遷移確率」「出力確率」の3概念を調べておこう