第7回：音声と統計モデル（HMM・GMM）＋自己教師あり表現学習

音声処理と認識

担当：小野原彩香｜北星学園大学｜3年後期

📌 この回は動画回です。Google Formsでテストを受けてください。

本回の到達目標

1. 従来型音声認識システムの全体アーキテクチャを説明できる
2. HMMの3要素を理解し、音声認識への応用を説明できる
3. GMMがHMMの出力確率モデルとしてどう機能するか理解する
4. 自己教師あり学習の概念を理解し、wav2vec 2.0とHuBERTの違いを説明できる

従来型音声認識の全体アーキテクチャ

従来型（〜2010年代前半）は **3つのモジュール** で構成

```
音声波形
  ↓ [特徴量抽出]  MFCC（前回まで学習済み）
  ↓ [音響モデル]  特徴量列 → 音素列
  ↓ [言語モデル]  音素列 → 単語列（文脈を加味）
  ↓ [デコーダ]    AM + LM を組み合わせ最尤テキストを出力
認識テキスト
```

モジュール	役割	代表技術
音響モデル（AM）	音の特徴量を音素に対応づける	GMM-HMM, DNN-HMM
言語モデル（LM）	単語の出現確率・文脈を学習	N-gram, LSTM
デコーダ	両モデルを統合し最尤パスを探索	Viterbiアルゴリズム

各モジュールは独立して設計・学習できるが、それぞれのエラーが累積する弱点もある

マルコフ連鎖の概念

マルコフ性（Markov Property）：現在の状態は直前の状態だけに依存する

$$P(q_t \mid q_{t-1}, q_{t-2}, \ldots, q_1) = P(q_t \mid q_{t-1})$$

天気のマルコフ連鎖（具体例）

状態集合 $Q = \{\text{晴れ}, \text{曇り}, \text{雨}\}$

$$A = \begin{pmatrix} 0.7 & 0.2 & 0.1 \\ 0.3 & 0.4 & 0.3 \\ 0.2 & 0.3 & 0.5 \end{pmatrix}$$

（行：現在の状態、列：次の状態）

> 音声では「状態 = 音素の一部（音素サブユニット）」と対応づける。音声は時間軸上で状態が遷移する過程として捉えられる。

HMMの3要素

$$\lambda = (A,\ B,\ \pi)$$

記号	名前	意味
$\pi_i = P(q_1 = i)$	**初期確率**	時刻1で状態iから始まる確率
$a_{ij} = P(q_{t+1} = j \mid q_t = i)$	**遷移確率**	状態iから状態jへ遷移する確率
$b_i(o_t) = P(o_t \mid q_t = i)$	**出力確率**	状態iにいるとき観測o_tが出力される確率

HMMが「隠れ」ている理由

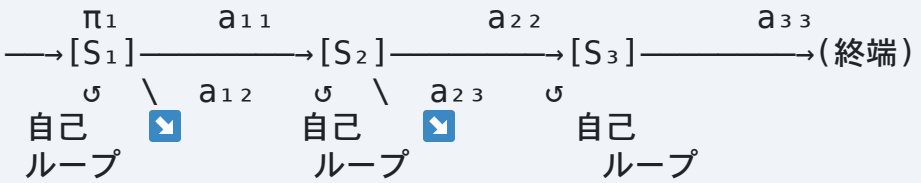
- 観測できるもの：音声の特徴量列 $O = (o_1, o_2, \ldots, o_T)$
- 観測できないもの：どの音素（状態）がどのフレームに対応するか

音声認識の目標 = 観測列Oから最も尤もらしい **隠れ状態系列（音素系列）** を求めること

音素HMMの構造（図解）

各音素に1つのHMMを割り当てる（通常3〜5状態）

音素 /a/ のHMM（3状態の例）：



各状態から特徴量ベクトルが出力される: $b_1(o)$, $b_2(o)$, $b_3(o)$

- 自己ループ確率 a_{ii} が高い → その状態が長く続く（話者・ペースの差を吸収）
- 単語のHMM = 音素HMMを直列につないだもの

HMMの3つの問題

1. **評価問題**：$P(O|\lambda)$ を求める → 前向きアルゴリズム
2. **復号問題**：最尤状態系列 Q^* を求める → **Viterbiアルゴリズム**
3. **学習問題**：$\lambda = (A, B, \pi)$ を推定する → Baum-Welchアルゴリズム

Viterbiアルゴリズムの直感的理解

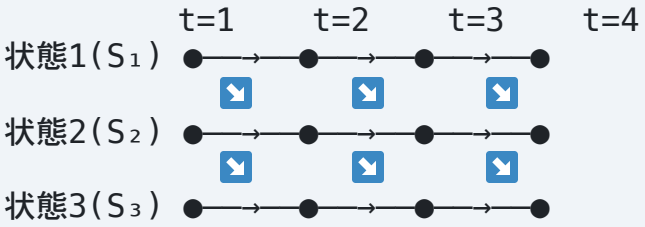
目標：観測列Oに対して最も確率が高い状態系列を求める

$$Q^* = \arg\max_{Q} P(Q, O \mid \lambda)$$

動的計画法：N^T 通りの全探索を $O(N^2 T)$ に削減

$$\delta_t(j) = \left[\max_i \delta_{t-1}(i) \cdot a_{ij}\right] \cdot b_j(o_t)$$

「時刻tに状態jにいる最良パスの確率」を順番に埋めていく



最後から後ろ向きにパスを追跡 → 最適状態系列

迷路の最短経路問題と同じ発想。「ここに来る最良の経路」だけを記録しながら前進する。

ガウス混合モデル（GMM）の基礎

多次元ガウス分布（MFCCは13〜39次元）：

$$\mathcal{N}(\mathbf{x};\boldsymbol{\mu},\boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})\right)$$

GMMとは：複数のガウス分布の **重み付き和** で複雑な分布を近似

$$p(\mathbf{x}) = \sum_{k=1}^{K} w_k \cdot \mathcal{N}(\mathbf{x};\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k)$$

- $w_k \geq 0, \sum_k w_k = 1$（混合重み）
- 音素/a/の特徴量空間 = 話者差・感情・速度による変動 → **多峰性の複雑な分布**
- GMMのK個の成分でこの分布を柔軟に近似できる

GMM-HMMシステム

HMMの各状態の **出力確率** $b_i(\mathbf{o})$ をGMMでモデル化：

$$b_i(\mathbf{o}) = \sum_{k=1}^{K} w_{ik} \cdot \mathcal{N}(\mathbf{o}; \boldsymbol{\mu}_{ik}, \boldsymbol{\Sigma}_{ik})$$

学習（EMアルゴリズム / Baum-Welch）

- Eステップ：現在のモデルで各フレームが各状態・成分に属する確率を計算
- Mステップ：その確率を使ってパラメータ（μ, Σ, w, A, π）を更新

深層学習への移行（DNN-HMM）

システム	WER（TIMIT）	特徴
GMM-HMM	～27%	従来標準
DNN-HMM	～20%	GMMをDNNに置換して大幅改善
End-to-End	～5%以下	次回詳述

自己教師あり学習とは

動機：ラベル付きデータは高コスト（1時間の音声転記に〜10時間の人手作業）

解決策：大量の**ラベルなし**音声データから有用な表現を学習する

```
[Stage 1: 事前学習]
  ラベルなし大規模データ（例：1000時間の音声）
  自己教師あり目標で学習 → 汎用的な音声表現
            ↓
[Stage 2: ファインチューニング]
  少量のラベル付きデータ（例：10時間）
  タスク特化の学習 → 高性能な認識モデル
```

Masked Prediction（マスク予測）

- テキスト（BERT）：単語をマスクして予測
- 音声（wav2vec 2.0, HuBERT）：音声フレームをマスクして予測

> 聞き取りにくい部分を文脈から推測するのに似た訓練。モデルは「音声の文脈」を学ぶ。

wav2vec 2.0 のアーキテクチャ

```
音声波形 x
  ↓ [CNN特徴抽出器]  波形 → 潜在特徴量列 z₁, z₂, ..., zT
    ↓                        ↓
  [量子化モジュール]   [Transformerエンコーダ]
  連続→離散トークン q    マスク→文脈化表現 c
    ↓
  [コントラスト学習]
  マスク位置の c から対応する q を正例として識別
```

コントラスト学習損失

$$\mathcal{L}_t = -\log \frac{\exp(\mathrm{sim}(\mathbf{c}_t, \mathbf{q}_t)/\kappa)}{\sum_{\tilde{\mathbf{q}} \in Q_t} \exp(\mathrm{sim}(\mathbf{c}_t, \tilde{\mathbf{q}})/\kappa)}$$

「この文脈から、どの音素コードが来るべきか？」を当てる訓練

HuBERT：オフラインクラスタリングによる学習

核心的アイデア：MFCCにk-meansをかけて**擬似ラベル**を作り、マスク予測で学習する

```
[イテレーション0]
  MFCCにk-meansクラスタリング → 擬似ラベル（k個のクラスタID）
  ↓
[Stage 1学習]  Transformerエンコーダを擬似ラベルの分類で学習
  ↓
[イテレーション1]
  Stage 1の特徴量にk-meansクラスタリング → 改良された擬似ラベル
  ↓ 繰り返す...
```

項目	wav2vec 2.0	HuBERT
離散化	量子化モジュール（end-to-end）	k-meansクラスタリング（オフライン）
損失関数	コントラスト学習	クロスエントロピー（マスク部分）

自己教師あり学習の驚くべき性能

wav2vec 2.0（960時間で事前学習）のファインチューニング結果（LibriSpeech WER）：

ファインチューニングデータ量	WER
10分	8.9%
1時間	5.7%
10時間	4.8%
100時間	3.4%
GMM-HMM（従来手法・960時間ラベル付き）	7.2%

わずか10分のラベル付きデータで従来手法に匹敵する性能

応用範囲：音声認識 / 感情・意図認識 / 話者認識 / 音声翻訳 / 言語識別

Google Forms テスト（全5問）

締め切り：翌週末 23:59

問1（HMMの3要素）：初期確率・遷移確率・出力確率の正しい説明の組み合わせはどれか
問2（Viterbiアルゴリズム）：最も確率の高い状態系列を動的計画法で求めるアルゴリズムはどれか
問3（GMMの特性）：「成分数Kを大きくすれば常に汎化性能が向上する」は正しいか
問4（wav2vec 2.0）：コントラスト学習で量子化ベクトルを正例、他の時刻を負例として識別するのはどれか
問5（自己教師あり学習の利点）：大量のラベルなしデータで事前学習し少量ラベルでファインチューニングできることが核心か

まとめ

概念	ポイント
従来型ASR	音響モデル（GMM-HMM）＋言語モデル＋デコーダの3モジュール
HMM	(A, B, π) の3要素。音素単位でモデル化
Viterbi	動的計画法で最尤状態系列を $O(N^2 T)$ で求める
GMM	複数ガウス分布の重み付き和で複雑な音響分布を近似
DNN-HMM	GMMをDNNに置換して大幅な性能向上
wav2vec 2.0	CNN＋Quantizer＋Transformerによるコントラスト学習
HuBERT	オフラインk-meansクラスタリングによる反復的な擬似ラベル学習

次回（第8回）：最新のEnd-to-Endモデル（Conformer・Whisper）の詳細と実際の使い方

Google Forms テスト

第7回の理解度テストを受けてください

- 全5問・各1点
- 締め切り：**翌週末 23:59**
- Google Formsのリンクはメールまたは授業ページで確認してください

お疲れさまでした！