第13回：応用事例と社会的インパクト

生成AI音声偽造・バイアス検証

音声処理と認識

小野原彩香 ／ 北星学園大学

📌 この回は動画回です。Google Formsでテストを受けてください。

この回の学習目標

1. 生成AI音声技術の技術的仕組みを説明できる
2. 音声Deepfakeが社会に与えるリスクを複数の観点から考察できる
3. 音声AIにおけるバイアスの問題を具体的に指摘できる
4. 技術者・研究者として倫理的責任を自分の言葉で表現できる

配慮事項

この回は動画視聴とCBTが中心です。
字幕付き動画を利用するなど、やれる範囲で自分のペースで進めてください。
テストは持ち込み可（紙メモ）。
時間や方法について相談があればメールでご連絡ください。

イントロダクション ― なぜ今この話をするのか

> 「あなたが電話で家族の声を聞いたとき、その声が本物かどうか、確認する手段はありますか？」

- 2023年：AIが生成した音声による詐欺被害が世界各地で急増
- 2024年：選挙前に政治家の偽音声が拡散

この授業で一緒に考えること

- 技術はどこまで進んでいるのか？
- 社会にどんな影響があるのか？
- 私たちは何をすべきか？何をすべきでないか？

TTS（音声合成）の進化

世代	代表技術	特徴
第1世代（〜2010年代前半）	規則合成・波形接続	ロボット声、不自然
第2世代（2016〜）	WaveNet（Google）	深層学習。初めて人間に近い自然さ
第3世代（2018〜）	Tacotron 2, FastSpeech	エンドツーエンド学習
第4世代（2021〜）	VITS, NaturalSpeech	発話速度・音調も制御
第5世代（2023〜）	VALL-E（Microsoft）	数秒の音声から声質模倣が可能

Zero-shot TTS — VALL-Eの衝撃

従来の課題：特定の話者の音声を生成するには、その人の音声データが大量に必要

VALL-E（2023, Microsoft）が実現したこと：

- **3秒の音声サンプル**からその人の声質を学習
- 任意のテキストをその人の声で読み上げ
- 背景ノイズや感情まで再現できる場合もある

```
入力音声（話者A） → VC モデル → 出力音声（話者Bの声で同じ内容）
```

> **技術的注意**：Zero-shot TTS の精度は話者・言語・録音環境によって大きく変わります。「完璧な模倣」が常に可能なわけではありません。

音声Deepfakeの生成技術

1. GAN（敵対的生成ネットワーク）ベース

```
生成器（Generator）：偽音声を生成
        ⬇️ 競争・改善
識別器（Discriminator）：本物と偽物を区別しようとする
```

代表例：WaveGAN、MelGAN、HiFi-GAN

2. 拡散モデル（Diffusion Model）ベース

ノイズから徐々に音声波形を復元するプロセスを学習。
代表例：DiffWave、AudioLDM、VoiceBox（Meta）

3. Autoencoder / VAE ベース

Voice Conversion（声質変換）に特に使われる。

実際に起きた事例

年	事例	概要
2019	英国 CEO 音声詐欺	親会社CEOに見せかけた音声で22万ユーロの振り込みを指示
2023	米大統領選予備選	バイデン氏の声に似せた音声が有権者に電話
2024	香港企業	会議中の幹部の声を偽造し、3,400万米ドルの送金詐欺
継続中	「オレオレ詐欺」進化版	家族の声に似せた音声で送金を要求

なぜ検出が難しいのか

1. **生成品質の向上**：人間の耳では区別できないレベルに近づきつつある
2. **短時間の音声で十分**：数秒〜数十秒あれば生成可能なケースも
3. **文脈の利用**：本物の情報（名前、状況）と組み合わせると信憑性が増す
4. **音声圧縮の問題**：電話やSNSでの圧縮により、偽造の痕跡が消えやすい

> **批判的視点**：「AIの音声はすぐわかる」という過信は危険です。一方で、「すべての音声が信用できない」という過度な不信感も社会を萎縮させます。

社会的インパクト①：詐欺・フィッシング

AI音声を使った詐欺の特徴

- 本人の声（SNS動画・インタビュー等から取得）を模倣
- 感情的なシナリオ（事故・逮捕・病気）と組み合わせ
- 標的の「家族の声」に特化したカスタマイズが可能に

対策として議論されていること

- 家族間の「合言葉」の設定
- 通話前の本人確認プロトコルの普及
- 音声Deepfake検出サービスの電話回線への組み込み

社会的インパクト②：政治的操作と「Liar's Dividend」

「Liar's Dividend（嘘つきの配当）」とは

> 「Deepfakeが存在するからこそ、本物の証拠を『フェイクだ』と否定できるようになる」
>
> — Nina Schick, *Deepfakes and the Infocalypse* (2020)

一緒に考えましょう

- Deepfake音声が「存在する」と知られているだけで、何が変わるでしょうか？
- 本物の証拠が偽物扱いされるリスクを、私たちはどう防ぐことができるでしょうか？

社会的インパクト③：声の権利と法規制

国・地域	主な規制・法整備
米国	ELVIS Act（テネシー州、2024）：AIによる声・肖像の無断使用を禁止
EU	AI Act（2024）：高リスクAIシステムの規制、Deepfakeの明示義務
中国	生成AI規制（2023）：AI生成コンテンツの標識義務
日本	AI事業者ガイドライン（2024）：法的拘束力は弱い

具体的な問題例

- 故人の声を無断で復元・商業利用
- 声優・歌手の声をAIで模倣した商品販売
- ニュースキャスターの声を偽情報に流用

Deepfake検出技術

スペクトル解析ベース

- 人工的に生成された音声にはスペクトル上に特有のパターンが残ることがある
- 高周波数域や声門の周期性に不自然さが現れる場合がある

機械学習ベース

システム	特徴
RawNet2	生の波形から直接特徴を学習
AASIST	グラフニューラルネットワークを利用
Wav2Vec-based	自己教師あり表現学習を活用

課題：学習に使った生成手法と異なる偽音声は検出精度が落ちる（汎化問題）

ASVspoof チャレンジ

音声偽造検出技術を競うベンチマークコンペティション。

年	版	主な焦点
2015	ASVspoof 2015	TTS・VC による攻撃の検出
2017	ASVspoof 2017	リプレイ攻撃（録音再生）の検出
2019	ASVspoof 2019	TTS・VC・リプレイを統合
2021	ASVspoof 2021	実環境条件（電話・圧縮）での検出
2024	ASVspoof 5	生成AI・拡散モデルへの対応

> ASVspoof の優勝システムでもラボ環境での精度は高いが、実際の電話詐欺環境では精度が大幅に低下することが知られています。

バイアスの問題：訓練データの偏り

多くの音声認識システムは、次のような話者が中心のデータで学習されています：
成人男性 / 標準的な発音 / 英語話者 / 健康な声道を持つ話者

話者属性	認識精度への影響
女性の声	基音周波数が高く、モデルの訓練分布と外れる場合がある
子供の声	声道が短く、フォルマント分布が大きく異なる
高齢者の声	声の揺れ（ジッター・シマー）が増加
非母語話者	アクセント・発音の違いにより誤認識が増加
吃音・構音障害	音声の非流暢性がモデルの前提と合わない

バイアスがもたらす社会的不平等

音声AIの恩恵が一部の話者グループにのみ届く状況は：

1. **アクセシビリティ**：音声インターフェースへのアクセスが制限される
2. **医療**：音声ベースの医療支援ツールが一部の患者に機能しない
3. **教育**：音声認識を使う学習ツールが特定の生徒に不利
4. **司法**：音声証拠分析ツールの信頼性に偏りが生じる可能性

前向きな動き

- Project Euphonia（Google）：非定型的な音声を持つ人々のデータ収集と認識改善
- Mozilla Common Voice：多様な話者データの収集

EU AI Act と音声AI

リスクベースの規制アプローチ（2024年施行）

リスクレベル	内容	規制
受け入れ不能リスク	社会的スコアリング等	禁止
高リスク	医療・司法・重要インフラ等	厳格な要件
限定リスク	チャットボット等	透明性義務
最小リスク	ゲーム、スパムフィルタ等	規制なし

音声AIに関連する規定

- **Deepfakeの明示義務**：AI生成の音声・動画は生成物であることを明示
- **感情認識AIの制限**：職場・教育機関での感情認識AI使用を原則禁止
- **バイオメトリクス識別**：公共空間でのリアルタイム音声識別を原則禁止

技術者としての倫理的責任

> "Just because you can, doesn't mean you should."
> （できることと、すべきことは別の問いです）

技術者が直面する倫理的ジレンマの例

1. 依頼された研究だが悪用リスクが高い場合
2. 精度を上げるためにプライベートな音声データを使いたい場合
3. バイアスを知りながらシステムをリリースする場合

一緒に考えましょう

> 音声処理・音声認識の技術者として、あなたはどのような社会を作ることに加担したいですか？

音声AIの責任ある使用

場面	責任ある実践	避けるべき実践
研究	参加者の同意を得た音声収集	無断でSNS音声を収集
開発	多様な話者データで訓練	偏ったデータで汎化と誤解する
展開	Deepfakeであることを明示	偽音声であることを隠す
評価	様々な話者グループで性能検証	平均精度だけで評価

まとめ：第13回

- **TTS進化**：WaveNet → VITS → VALL-E で少量データでの声模倣が可能に
- **音声Deepfake**：GAN・拡散モデルで生成され、検出が難しい理由が複数ある
- **社会的インパクト**：詐欺・政治的操作・著作権問題など多岐にわたる
- **Liar's Dividend**：Deepfakeの存在が本物の証拠の信頼性も脅かす
- **バイアス**：訓練データの偏りが特定の話者への不公平な認識精度として現れる
- **倫理的責任**：「技術を作るだけ」の技術者にも存在する

CBTテスト・次回予告

> 📌 **CBTテスト（Google Forms）**
>
> 5問・持ち込み可（紙メモ）・30分
> 締め切り：翌週末 23:59

第14回（オンライン同期）：まとめと最終発表

- 授業全体の振り返り（14回の学習内容マップ）
- 期末プロジェクト・レポートの説明と質疑
- 最終発表セッション

発表が困難な場合は、事前録画・スライド+テキスト・書面レポートでの代替が認められています。