第14回：まとめと最終発表

音声処理と認識

小野原彩香 ／ 北星学園大学

📌 Zoom録画を後日公開します。課題はメール/Google Driveでも提出可。

この回の目標

1. 14回の授業を通じて学んだ内容を体系的に振り返る
2. 期末プロジェクトの要件と評価基準を正確に理解する
3. 発表・報告を通じて自分の学びと考察を他者と共有する
4. 音声処理・認識の技術と社会的意義を統合的に理解する

配慮事項

この回は発表セッションが含まれます。
口頭発表が困難な場合は、以下の代替形式を認めています：

- 事前録画動画の再生
- スライド＋テキストチャットでの説明
- 書面レポートのみでの代替

不安な場合はメールで小野原まで相談してください。

授業の流れ（90分）

時間	内容
00〜10分	授業全体の振り返り（概念マップ）
10〜20分	期末プロジェクト・レポートの説明と質疑
20〜70分	最終発表セッション（1発表あたり20〜25分）
70〜80分	フィードバックと全体質疑
80〜90分	授業アンケートの案内・クロージング

> 発表グループ数・時間配分は受講者数により調整します。

14回の学習マップ — 基礎

第1回　音声とは何か
　　↓ 物理的な音の性質（波形・周波数・振幅）
第2回　音声の特徴量
　　↓ MFCC・メルスペクトログラム・ケプストラム
第3回　音声処理の基礎（前処理・フレーム分析）

14回の学習マップ — 認識の仕組み

```
第4回　音声認識の歴史（DTW → HMM → 深層学習）
　　↓
第5回　深層学習による音声認識（CNN・RNN・CTC）
　　↓
第6回　Transformer と注意機構（Self-Attention）
　　↓
第7回　最新モデル（Whisper・wav2vec 2.0 等）
```

14回の学習マップ ― 生成・変換と応用

```
【音声の生成・変換】
第8回　　音声合成（TTS）の基礎
　　　　↓
第9回　　音声変換・声質変換（Voice Conversion）

【応用】
第10回　音声インタフェース・音声エージェント
第11回　NLUと音声：意図理解・対話管理・LLM統合
第12回　感情・韻律・認知科学・神経多様性

【社会・倫理】
第13回　音声Deepfake・バイアス・倫理
第14回　まとめと最終発表　← 今日
```

覚えておいてほしい 10 のキーワード

#	キーワード	一言説明
1	MFCC	音声の特徴量として最も広く使われる
2	HMM	深層学習以前の音声認識の中核技術
3	CTC	系列変換の損失関数
4	Transformer	現代の音声認識・合成の基盤アーキテクチャ
5	Whisper	OpenAIの多言語音声認識モデル
6	TTS / Voice Conversion	2大音声生成技術
7	GAN / 拡散モデル	高品質な音声生成の深層学習手法
8	話者照合 (ASV)	声による本人確認システム
9	バイアス	訓練データの偏りが引き起こす認識精度の不平等
10	Deepfake / ASVspoof	AI生成偽音声とその検出の競争

技術の「縦軸」と「横軸」

縦軸：技術の深さ（How it works）

> 波形レベル → 特徴量レベル → モデルレベル → システムレベル → サービスレベル

横軸：技術の広がり（What it touches）

> 認識 ←――――――――――――――――→ 生成
> 個人 ←――――――――――――――――→ 社会
> 技術 ←――――――――――――――――→ 倫理

この授業では意図的に「縦（仕組み）」と「横（影響）」の両方を扱いました。

音声処理と認識の「大きな問い」

技術的な問い

- どうすれば音声を正確に認識・生成できるのか？
- 少ないデータでも頑健に機能するモデルをどう作るか？

社会的な問い

- 音声AIは誰のために作られているのか？
- 誰が恩恵を受け、誰が排除されているのか？

個人的な問い

- あなたはどんな技術を、誰のために作りたいか？

> 期末プロジェクトでは、これらの問いのどれかに対するあなた自身の答えを示してください。

期末プロジェクト：テーマ選択肢

テーマ	タイトル	難易度
A	音声特徴量分析レポート	★★★☆☆
B	Whisperを使った多言語音声認識の精度比較	★★★★☆
C	音声インタフェースのUX提案書	★★★☆☆
D	音声Deepfake検出の調査報告（技術+倫理）	★★★☆☆
E	自由テーマ（音声処理・認識に関連するもの）	—

提出締め切り・詳細：別途メールでご連絡します。
Google Drive またはメールでも提出可。

テーマA：音声特徴量分析レポート

自分で収録した音声をMFCC等で分析し、分析結果とその解釈を報告する。

内容の例

- 自分の声・友人の声・異なる感情で発話した音声を比較
- 静かな環境と騒がしい環境での認識精度の変化

使用ツール（推奨）：Python（librosa, matplotlib）、Praat、Google Colab

成果物：分析コード＋結果グラフ、レポート（4,000〜6,000字）、発表スライド（8〜12枚）

テーマB：Whisperを使った多言語音声認識の精度比較

OpenAI の Whisper を使って、複数の言語・方言・話者属性での精度を比較する。

比較の切り口例

- 言語別（英語 vs. 日本語 vs. スペイン語 等）
- 方言別（標準語 vs. 関西弁 vs. 東北方言等）
- 話者属性別（成人男性 vs. 女性 vs. 子供 vs. 高齢者）

評価指標：WER（Word Error Rate）

$$\mathrm{WER} = \frac{S + D + I}{N} \times 100\%$$

S：置換、D：削除、I：挿入、N：正解トークン数

テーマC：音声インタフェースのUX提案書

特定のユーザー・用途を想定した音声インタフェースのデザイン案を作成する。

提案のフレームワーク

1. 誰のための設計か（ユーザーペルソナ）
2. どんな場面で使うか（ユースケース・シナリオ）
3. 音声インタフェースの設計原則（エラー対応・プライバシー配慮）
4. インクルーシブデザイン・アクセシビリティの視点
5. プロトタイプ（モックアップ・フロー図・音声サンプル等）

プログラミングは任意（プロトタイプを実装する場合）。

テーマD：音声Deepfake検出の調査報告

音声Deepfakeの生成技術・検出技術を調査し、技術的・倫理的両面から報告する。

構成例

1. 音声Deepfakeの生成技術の概要（GAN・拡散モデル・Zero-shot TTS）
2. 検出技術の現状（ASVspoof・機械学習ベース検出器）
3. 社会的インパクトの事例（詐欺・政治的操作等）
4. 規制・倫理ガイドラインの動向（EU AI Act等）
5. 自分の見解と技術者として考えること

テーマE：自由テーマ

音声処理・音声認識に関連するテーマを自由に設定して報告する。

自由テーマの条件

1. 音声処理・音声認識の技術的内容が含まれていること
2. 自分の分析・考察・見解があること
3. テーマを事前に担当者に報告し、承認を得ること

アイデア例

- 音楽情報処理（楽器音の認識・楽曲生成）
- 吃音者向けの音声インタフェース改善提案
- 日本語の方言認識の課題と展望
- ポッドキャスト自動文字起こしの精度評価

評価ルーブリック（100点満点）

項目	配点	優秀の基準
内容の正確さ	30点	技術的内容が正確、最新情報を参照、専門用語が適切
分析・考察の深さ	30点	複数の視点から考察、技術と社会・倫理の両面を統合
発表/報告の明確さ	20点	構成が論理的、聴衆を意識、図表が効果的
独自性・創造性	20点	独自の視点・アイデア・分析がある

評価ルーブリック — 詳細（考察の深さ）

評価段階	点数	基準
優秀	27〜30点	事実の記述にとどまらず、複数の視点から深く考察している。技術と社会・倫理の両面を統合した分析がある
良好	21〜26点	考察があり、自分の見解が示されている。ただし一部に浅い部分がある
基準達成	15〜20点	考察が表面的。既存情報をまとめることが中心
基準未達	0〜14点	考察がほとんどなく、情報の羅列にとどまる

> **注意**：剽窃（他者の文章・コードの無断転用）は評価対象外。引用の場合は必ず出典を明記してください。

発表形式の選択肢（神経多様性への配慮）

どの形式を選んでも、**評価の基準は同じ**です。

形式	内容	適した場合
A: 口頭発表（標準）	スライドを使いながら口頭で発表（20〜25分）	口頭発表が問題ない場合
B: 事前録画動画の再生	事前に録画した動画を授業中に再生	発話不安・声・発音に困難がある場合
C: スライド＋テキスト説明	スライド共有しながらチャットで説明	発話が困難・選択的緘黙等の場合
D: 書面レポートのみ	発表なし、詳細なレポートで代替	同期オンライン参加が著しく困難な場合

形式の選択理由を説明する必要はありません。

発表セッションの進め方

1発表あたりの流れ（20〜25分）

```
00〜15分: 発表
15〜20分: 質疑応答
20〜25分: フィードバックコメント（担当者から）
```

質問について

- Zoom のチャット機能での質問も受け付けます
- 「批判」ではなく「好奇心」からの質問を歓迎します
- 「自分が理解できなかった部分を聞く」質問も大歓迎です

担当者から伝えたかったこと

音声処理・音声認識は「面白い技術」であると同時に、「社会と深く結びついた技術」です。

どんな素晴らしい技術も、それが誰かを傷つけたり、不平等を拡大したりするために使われるなら、技術者はそのことを考え続ける責任があります。

反対に、技術は誰かの声を届け、誰かのアクセシビリティを高め、誰かの生活を豊かにすることができます。

この授業がその両方を考え続けるための出発点になれば、担当者としてとても嬉しいです。

技術が解決できたこと・できないこと

解決できたこと	依然として難しいこと
標準的な発音の高精度認識	多様な話者への公平な認識
自然な音声合成	声の「権利」の保護
少量データでの声模倣	Deepfakeの完全な検出
リアルタイム処理	バイアスの根本的な解消

> 良い技術者は、コードを書く能力だけでなく、その影響について考える想像力を持っています。

まとめ：第14回・そしてこの授業全体

- 14回を通じて「音声の物理」から「AIの倫理」まで縦断しました
- 技術の進化は止まらない。学び続ける姿勢が大切です
- **「誰のための技術か」を問い続けることが、良い技術者の第一歩です**

授業アンケートと提出について

> **📌 授業アンケート（匿名・Google Forms）**
>
> 難易度・授業形式・神経多様性への配慮について率直なご意見を歓迎します。
> 担当者へのメッセージも大歓迎です。

期末プロジェクト提出

- 提出方法：Google Drive またはメール添付
- 締め切り：翌週末 23:59（別途メールでご連絡します）

ありがとうございました。